RECOLETA TREND BRIEF

代码代理进入仓库执行闭环：真实评测、验证前移与安全治理升温

Week trend brief with overview, must-read papers, and cluster notes.

10 tracked topics

WINDOW
Week

PERIOD
2026-W10 (2026-03-02 to 2026-03-09)

TOPICS
10

OVERVIEW

本周的软件工程与代码智能研究，主线很集中：代理不再只比会不会写，而是比能否理解仓库、完成执行闭环，并在长期运行中保持可靠与可审计。关键观察-仓库理解前置：成功率越来越取决于是否先看懂架构、补全任务说明，再开始改代码。-评测更像真实开发：基准从单点修复扩展到跨仓库、完整应用交付和持续维护。-验证前移：回归测试、环境搭建、问题复现和执行反馈，成为核心能力。

CLUSTERS

仓库级代码代理转向“先理解，再执行”

本周最清晰的主线，是代码代理开始从“局部生成”转向“仓库级执行”。研究重点放在先理解代码库，再决定改哪里、怎么改、如何验证。RAIM强调架构感知定位、多方案生成与影响分析；CodeScout则说明，先把含糊问题改写成可执行任务，往往比直接开工更稳。这说明上游理解与任务准备，正在成为真实修复成功率的关键杠杆。

REPRESENTATIVE PAPERS

- Architecture-Aware Multi-Design Generation for Repository-Level Feature Addition — Mingwei Liu; Zhenxi Chen; Zheng Pei; Zihao Wang; Yanlin Wang; Zibin Zheng
- CodeScout: Contextual Problem Statement Enhancement for Software Agents — Manan Suri; Xiangci Li; Mehdi Shojaie; Songyang Han; Chao-Chun Hsu; Shweta Garg; …

评测从“会写代码”升级到真实软件工程

本周大量材料都在抬高评测难度。BeyondSWE把任务扩展到跨仓库、依赖迁移和文档到仓库生成；Vibe Code Bench要求交付完整 Web 应用；SWE-CI把目标转向持续维护代码库。共同信号很一致：单题通过已不够，行业开始用更接近真实开发的流程来衡量代理能力，而当前成功率仍不高。

REPRESENTATIVE PAPERS

- BeyondSWE: Can Current Code Agent Survive Beyond Single-Repo Bug Fixing? — Guoxin Chen; Fanzhe Meng; Jiale Zhao; Minghao Li; Daixuan Cheng; Huatong Song; …
- SWE-CI: Evaluating Agent Capabilities in Maintaining Codebases via Continuous Integration — Jialong Chen; Xander Xu; Hu Wei; Chuan Chen; Bing Zhao
- Vibe Code Bench: Evaluating AI Models on End-to-End Web Application Development — Hung Tran; Langston Nashold; Rayan Krishnan; Antoine Bigeard; Alex Gu
- Key takeaways from the 2026 State of Software Delivery — Illniyar
- From Leaderboard to Deployment: Code Quality Challenges in AV Perception Repositories — Mateus Karvat; Bram Adams; Sidney Givigi
- CodeTaste: Can LLMs Generate Human-Level Code Refactorings? — Alex Thillen; Niels Mündler; Veselin Raychev; Martin Vechev

验证与执行闭环成为代理落地的硬门槛

验证正在从收尾步骤前移为核心系统能力。AgentAssay说明，面对非确定性代理，回归测试需要统计式方法而不是一次性判定。RepoLaunch补齐了跨语言、跨平台的构建与测试环境自动化。Echo进一步把检索、生成、执行、验证串成闭环。趋势很明确：谁能稳定跑通环境、复现问题、低成本回归，谁才更接近生产可用。

REPRESENTATIVE PAPERS

- RepoLaunch: Automating Build&Test Pipeline of Code Repositories on ANY Language and ANY Platform — Kenan Li; Rongzhi Li; Linghao Zhang; Qirui Jin; Liao Zhu; Xiaosong Huang; …

自纠错、记忆与多代理协作走向系统工程

本周另一条强线是工程化补课。ReflexiCoder把“生成—反思—修正”纳入训练，试图把自纠错学进模型参数。Modulus和终端代理工作总结都强调共享记忆、隔离工作区、脚手架与上下文工程。Memory for Autonomous LLM Agents 则把记忆机制提升为独立研究主题。说明代理竞争点正从单次答案质量，转向长时任务中的稳定性、协作性与可恢复性。

REPRESENTATIVE PAPERS

- Building Effective AI Coding Agents for the Terminal: Scaffolding, Harness, Context Engineering, and Lessons Learned — Nghi D. Q. Bui
- Show HN: Modulus — Run multiple coding agents with shared project memory — dasubhajit

安全治理从提示防护走向语言、审计与故障分析

安全与可审计性在本周明显前移。日趋势多次提到可验证治理、审计、回滚和数据流约束。Turn尝试把类型、安全和持久执行写进语言层；故障分类与失败解释工作则把代理失效从“黑箱问题”转成可观察、可归因的问题。相比早期只做提示防护，现在更像是在建设一套面向代理系统的治理底座。

REPRESENTATIVE PAPERS

- Characterizing Faults in Agentic AI: A Taxonomy of Types, Symptoms, and Root Causes — Mehil B Shah; Mohammad Mehdi Morovati; Mohammad Masudur Rahman; Foutse Khomh

代码智能开始追求结构化推理与真实性能最优

除了通用编码，本周也看到高性能与结构化代码智能升温。CUDA Agent把强化学习带到 CUDA 内核优化，说明代码生成开始用真实机器性能做目标，而非只看语法正确。另一边，KCoEvo和补丁正确性评估工作都强调程序图、版本关系和结构化表示。这意味着代码智能正在从纯文本预测，转向更重结构和外部信号的路线。

REPRESENTATIVE PAPERS

- CUDA Agent: Large-Scale Agentic RL for High-Performance CUDA Kernel Generation — petethomas
- On the Effectiveness of Code Representation in Deep Learning-Based Automated Patch Correctness Assessment — Quanjun Zhang; Chunrong Fang; Haichuan Hu; Yuan Zhao; Weisong Sun; Yun Yang; …